

Redes Convolucionales Profundas en Predicción de Deforestación en Colombia

Luis Andrés Rodríguez Florián , Angel David Gomez Pastrana.

*Departamento de Matemáticas, Facultad de Ciencias, Universidad Nacional de Colombia, Cra. 45 # 26 - 85,
Bogotá D.C., Colombia.
lurodriguez@unal.edu.co, angomezp@unal.edu.co*

Resumen: La deforestación en la Amazonía colombiana constituye un desafío ambiental crítico que requiere transitar de sistemas de monitoreo reactivos hacia modelos de pronóstico espacial proactivos. En este artículo se evalúa el riesgo espacial de deforestación en el municipio de Mapiripán (Meta), un núcleo activo identificado por el IDEAM. Para ello, se adaptó la arquitectura espaciotemporal de Ball et al. (2022) mediante la red MDFNet, la cual procesa variables estáticas y series temporales extraídas del conjunto de datos Global Forest Change (bandas multiespectrales Landsat y capas históricas de pérdida a 30 metros de resolución). Se evaluaron tres escenarios de muestreo sobre el conjunto de entrenamiento. La configuración *Baseline* (sin submuestreo) presentó el mejor rendimiento en el conjunto de prueba independiente (F_1 -score = 0,8546, ROC -AUC = 0,9949, Precisión = 85,44 % y Sensibilidad = 85,47 %), superando a las estrategias de submuestreo. La proyección prospectiva para el año 2026 estimó una pérdida de 1918 píxeles ($\approx 172,6$ ha), espacialmente concentrada de forma contigua a los frentes históricos de transformación. Estos resultados confirman la efectividad de las redes convolucionales bimodal-temporales para proyectar patrones de deforestación y respaldar la toma de decisiones preventivas.

Palabras Clave: Amazon, Artificial Intelligence, Convolutional Neural Networks, Deep Learning, Deforestation Forecasting, Machine Learning, Spatial Forecasting, Tropical Forests.

1. Introducción

La deforestación representa una amenaza global crítica para la biodiversidad y la mitigación del cambio climático. En el contexto colombiano, la pérdida de cobertura forestal se concentra principalmente en la región Amazónica, un ecosistema sometido a alta presión antrópica [1]. Si bien la disponibilidad masiva de imágenes satelitales ha revolucionado el monitoreo forestal automatizado [2], los sistemas de alerta temprana actuales presentan una limitación inherente: operan de manera reactiva, detectando el daño únicamente después de que la transformación del ecosistema ya ha ocurrido.

Para superar esta limitación, resulta útil el desarrollo de sistemas predictivos capaces de anticipar la evolución espacial de la deforestación que ayuden optimizar la toma de decisiones ambientales. Dada la complejidad y la multiplicidad de variables involucradas (e.g., expansión agropecuaria e infraestructura), el

aprendizaje profundo (Deep Learning) se perfila como una solución prometedora. Trabajos recientes han demostrado que arquitecturas como las Redes Neuronales Convolucionales (CNN) y ConvLSTM logran pronosticar con alta precisión la ubicación de futuros eventos de deforestación utilizando exclusivamente secuencias históricas de datos satelitales públicas [3], sentando las bases para una gestión ecosistémica proactiva.

En este contexto, el objetivo de este artículo es presentar y evaluar una adaptación de la arquitectura propuesta por Ball et al. [3]. Específicamente, se busca con esta arquitectura pronosticar el riesgo espacial de deforestación para la región de Mapiripán (Meta) uno de los núcleos que presentan mayor deforestación en la Amazonia [1], utilizando los datos públicos presentes en el proyecto *Global Forest Change*.

2. Metodología

2.1. Área de Estudio

El municipio de Mapiripán (Meta) fue seleccionado como área de estudio debido a que constituye uno de los principales núcleos activos de deforestación de la Amazonía colombiana. De acuerdo con el Boletín de Detección Temprana de Deforestación (DTD) esta zona presenta una dinámica persistente de pérdida de cobertura forestal, concentrada principalmente entre los ríos Iteviare y Siare [1][4]. Este patrón evidencia un proceso de expansión espacial de la deforestación, lo que convierte a la región en un escenario adecuado para el estudio, entrenamiento y evaluación de modelos predictivos. Para optimizar el costo computacional y enfocarse en la zona de mayor pérdida, se delimitó un área de estudio de 15×15 km centrada en las coordenadas 3.30°N y 71.55°O .

2.2. Conjunto de Datos de Entrenamiento

El conjunto de datos de entrenamiento se construyó a partir de los mapas del Global Forest Change (GFC) [2][5]. Siguiendo la metodología de Ball et al. [3], nuestro modelo va evalúa el riesgo de deforestación procesando el contexto local mediante ventanas espaciales de 17×17 píxeles. Se extrajo información histórica del periodo 2022-2024 para evaluar los modelos en el año 2025. Cada muestra se compone de la etiqueta del píxel objetivo, variables dinámicas temporales y características estáticas. Nuestro tensor de entrada consta de dos canales principales:

Variables Estáticas y Filtrado: Se incluyó la cobertura arbórea base (`treecover2000`) y la ganancia forestal (`gain`). Para mitigar el desbalance de clases y excluir áreas irrelevantes, la muestra se restringió a superficies terrestres válidas (`datamask`) con una cobertura inicial $\geq 30\%$.

Variables Dinámicas (2022-2024): La evolución del entorno se codificó en un tensor temporal de 8 canales. Este incluye cuatro bandas multispectrales Landsat (Rojo, NIR, y dos SWIR) y cuatro capas de pérdida forestal histórica (`recent_loss`). Estas últimas agrupan la deforestación previa en intervalos de 0-1, 2-4, 5-8 y >8 años.

Etiquetado: La variable objetivo es binaria, asignando un valor de 1 exclusivamente si el píxel central experimentó deforestación en el año objetivo (2025), y

0 en caso contrario.

2.3. Arquitectura Base (Ball et al., 2022)

La adopción de la arquitectura CNN 3D propuesta por Ball et al. [3][6] se fundamenta en su capacidad para procesar directamente los dominios espacial y temporal, alcanzando un alto desempeño predictivo (F1-Score de 0.715). Estructuralmente, el modelo implementa un diseño paralelo de dos ramas: una rama Conv2D encargada de extraer las características del contexto estático, y una rama Conv3D que codifica y comprime la secuencia temporal de las variables dinámicas. Las representaciones latentes de ambas ramas se concatenan y son procesadas de forma unificada mediante capas Conv2D adicionales, reducción dimensional vía *Spatial Pyramid Pooling* (SPP) y clasificadas mediante dos capas de redes completamente conectadas (FC). El valor obtenido es pasado por función sigmoide que nos devuelve un valor que se puede interpretar como la probabilidad deforestación del píxel el año siguiente. Esta arquitectura se puede resumir de la siguiente manera:

$$\begin{aligned} \mathbf{X}^j &\in \mathbb{R}^{8 \times 3 \times (2r+1) \times (2r+1)} \rightarrow 2 \times (\text{Conv3D} \rightarrow \text{ReLU} \rightarrow \text{BN3D}) \rightarrow Z_x^j \in \mathbb{R}^{c_1, h, w} \\ \mathbf{S}_j &\in \mathbb{R}^{2 \times (2r+1) \times (2r+1)} \rightarrow 2 \times (\text{Conv2D} \rightarrow \text{ReLU} \rightarrow \text{BN2D}) \rightarrow Z_s^j \in \mathbb{R}^{c_2, h, w} \\ \mathbf{Z}^j &\in \mathbb{R}^{(c_1+c_2), h, w} \rightarrow 2 \times (\text{Conv2D} \rightarrow \text{ReLU} \rightarrow \text{BN2D}) \rightarrow \text{SPP}(n, k) \rightarrow \text{FC}(spp, 100) \rightarrow \text{ReLU} \rightarrow \text{BN1D} \rightarrow \text{DO}(p) \rightarrow \text{FC}(100, 1) \rightarrow \sigma \rightarrow \hat{Y}_{t+1}^j \end{aligned}$$

2.4. Adaptación del Modelo

Para mitigar las exigencias computacionales de la arquitectura 3D CNN original [3] sin comprometer su razonamiento bimodal estático-temporal, se desarrolló la red adaptada *MDFNet*. La arquitectura procesa parches espaciales de 17×17 píxeles a través de tres etapas principales:

Rama estática: Mapea el tensor estático de entrada ($2 \times 17 \times 17$) a una representación $Z_s \in \mathbb{R}^{16 \times 17 \times 17}$ mediante dos bloques Conv2D–BN2D–ReLU.

Rama temporal: Procesa una secuencia de 5 años con 8 canales ($8 \times 5 \times 17 \times 17$). Utiliza un bloque Conv3D para extracción espacio-temporal y una Conv3D asimétrica ($3 \times 1 \times 1$) para comprimir la dimensión temporal, generando el mapa $Z_t \in \mathbb{R}^{16 \times 17 \times 17}$.

Fusión y clasificación: Las representaciones Z_s y Z_t se concatenan a lo largo de los canales ($32 \times 17 \times 17$)

y se procesan con capas Conv2D. Posteriormente, un módulo (SPP) reduce el volumen a un vector de 336 dimensiones, el cual se clasifica mediante capas completamente conectadas con regularización *Dropout* ($p = 0,2$) y activación sigmoide.

Esta arquitectura esta resumida de la siguiente manera:

$$\begin{aligned} \mathbf{X}^j &\in \mathbb{R}^{8 \times 5 \times 17 \times 17} \rightarrow 2 \times (3\text{DConv} \rightarrow 3\text{DBN} \rightarrow \text{ReLU}) \rightarrow Z_t^j \in \mathbb{R}^{16 \times 17 \times 17} \\ \mathbf{S}^j &\in \mathbb{R}^{2 \times 17 \times 17} \rightarrow 2 \times (2\text{DConv} \rightarrow 2\text{DBN} \rightarrow \text{ReLU}) \rightarrow Z_s^j \in \mathbb{R}^{16 \times 17 \times 17} \\ \mathbf{Z}^j &\in \mathbb{R}^{32 \times 17 \times 17} \rightarrow 2 \times (2\text{DConv} \rightarrow 2\text{DBN} \rightarrow \text{ReLU}) \rightarrow \text{SPP}(1 \times 1, 2 \times 2, 4 \times 4) \rightarrow \text{FC}(336, 16) \rightarrow \text{ReLU} \rightarrow \text{DO}(0,2) \rightarrow \text{FC}(16, 1) \rightarrow \sigma \rightarrow \hat{Y}_{t+1}^j \end{aligned}$$

2.5. Configuración Experimental

El conjunto de datos se dividió mediante muestreo estratificado en tres subconjuntos independientes: entrenamiento (60 %), validación (20 %) y prueba (20 %). Los conjuntos de validación y prueba mantuvieron la distribución espacial real del territorio. En el conjunto de entrenamiento se evaluaron tres escenarios de submuestreo (*undersampling*) sobre la clase negativa para controlar el sesgo por desbalance de clases:

Baseline: Conserva la distribución natural de clases sin submuestreo.

Undersampling 1:15: Proporción ajustada de 1 muestra positiva por cada 15 negativas.

Undersampling 1:10: Proporción ajustada de 1 muestra positiva por cada 10 negativas.

2.6. Estrategia de Entrenamiento

El entrenamiento del modelo se optimizó minimizando la función de pérdida de entropía cruzada binaria ($\mathcal{L}_{\text{BCE}}$):

$$\mathcal{L}_{\text{BCE}} = -\frac{1}{N} \sum_{i=1}^N [y_i \log(\sigma(z_i)) + (1 - y_i) \log(1 - \sigma(z_i))]$$

donde z_i representa la salida no normalizada para el píxel i , $\sigma(\cdot)$ denota la función sigmoide y $y_i \in \{0, 1\}$ la etiqueta real de cobertura.

La actualización de parámetros se realizó mediante el optimizador *Adam* con una tasa de aprendizaje inicial de $\alpha = 10^{-3}$, tamaño de lote de 64 muestras y un límite de 200 épocas. Se aplicó una atenuación adaptativa que reduce α por un factor de 0,5 (hasta un límite

de 10^{-6}) tras 3 épocas consecutivas de estancamiento en la pérdida de validación. Para evitar el sobreajuste, se implementó una detención temprana (*early stopping*) con paciencia de 25 épocas, preservando los pesos que alcanzaron el mayor valor de *ROC-AUC* en validación.

2.7. Métricas de Desempeño

La evaluación del modelo se ejecutó sobre el conjunto de prueba independiente aplicando un umbral óptimo de decisión de probabilidad τ^* , previamente calibrado durante la fase de validación. El desempeño discriminatorio se determinó cuantitativamente mediante las métricas de función de pérdida en Test ($\mathcal{L}_{\text{BCE}}$), Precisión, Sensibilidad (*Recall*), F_1 -score y el Área Bajo la Curva ROC (*ROC-AUC*).

3. Resultados

3.1. Evaluación Comparativa de Experimentos

La Cuadro 1 resume el desempeño cuantitativo de los tres experimentos evaluados sobre el conjunto de Test independiente (20 % de los datos), el cual conservó la distribución espacial real del territorio.

Contrario a la hipótesis inicial sobre la necesidad de balancear artificialmente las clases, la configuración **Baseline** (sin submuestreo) alcanzó el rendimiento superior en todas las métricas evaluadas. Obtuvo el menor valor de pérdida en prueba ($\mathcal{L}_{\text{BCE}} = 0,0359$), una precisión de 85,44 %, una sensibilidad (*recall*) de 85,47 % y un F_1 -score de 0,8546.

Las estrategias de submuestreo (*1:15* y *1:10*) convergieron de manera más temprana (época 39) y requirieron umbrales de decisión mayores ($\tau^* = 0,73$ y $\tau^* = 0,79$, respectivamente), pero experimentaron un leve deterioro en la capacidad de discriminación general, reduciendo el F_1 -score a 0,8230 y 0,8281. Esto sugiere que preservar la variabilidad completa de las muestras negativas durante el entrenamiento permite a la red *MDFNet* aprender representaciones contextuales más robustas del trasfondo no deforestado sin sobreestimar el riesgo de cambio.

Cuadro 1: Desempeño cuantitativo de la arquitectura *MDFNet* en el conjunto de Testing para las diferentes estrategias de muestreo.

Experimento	Época Opt.	τ^*	Pérdida ($\mathcal{L}_{BCE}$)	Precisión	Sensibilidad	F_1 -score	$ROC-AUC$
<i>Baseline</i>	47	0.60	0.0359	0.8544	0.8547	0.8546	0.9949
<i>Undersampling 1:15</i>	39	0.73	0.0396	0.8230	0.8230	0.8230	0.9932
<i>Undersampling 1:10</i>	39	0.79	0.0416	0.8315	0.8247	0.8281	0.9932

3.2. Análisis del Desempeño del Modelo Óptimo

El modelo óptimo correspondió a la configuración *Baseline* en la época de entrenamiento 47, evaluado con un umbral óptimo de probabilidad $\tau^* = 0,60$. La métrica de área bajo la curva ROC ($ROC-AUC = 0,9949$) evidencia una sobresaliente capacidad para clasificar píxeles deforestados y no deforestados a través de distintos umbrales de decisión.

El equilibrio logrado entre la precisión (85,44 %) y la sensibilidad (85,47 %) demuestra que el modelo no padece de un sesgo hacia falsos positivos ni hacia una omisión alta de eventos de deforestación reales. La Figura 3 ilustra la matriz de confusión resultante en el subconjunto de prueba desacoplado.

3.3. Pronóstico Espacial de Deforestación para el Año 2026

Una vez validado el desempeño del modelo *Baseline*, se ejecutó la fase de inferencia prospectiva para predecir los patrones de deforestación en el área de estudio durante el año 2026. La ventana espacial analizada abarca un total de 313,599 píxeles válidos (equivalentes a la grilla de $15 \times 15 \text{ km}^2$ con el área de protección).

Aplicando el umbral óptimo de decisión $\tau^* = 0,60$, el modelo pronostica una transformación forestal activa de **1,918 píxeles** para el año 2026 (aproximadamente 172,6 hectáreas, considerando la resolución espacial de 30 m por píxel).

Como se observa en la Figura 2, los píxeles predichos con alto riesgo de deforestación se concentran de manera contigua a los frentes de pérdida histórica previa, reproduciendo la dinámica de expansión espacial nucleada característica de este sector del municipio de Mapiripán.

4. Conclusiones

En este estudio se evaluó la arquitectura CNN 2D/3D *MDFNet* para la estimación del riesgo espacial de deforestación en Mapiripán (Meta), empleando series temporales del producto *Global Forest Change*.

A partir de los experimentos realizados se obtuvieron las siguientes conclusiones:

Distribución de clases: La configuración *Baseline* (sin submuestreo) obtuvo los valores de desempeño más altos (F_1 -score = 0,8546, $ROC-AUC = 0,9949$, Precisión = 85,44 % y Sensibilidad = 85,47 %), superando a los escenarios con submuestreo. Esto indica que mantener la variabilidad completa de las clases negativas reduce la tasa de falsos positivos sin necesidad de balancear artificialmente los datos de entrenamiento.

Calibración de umbral: La determinación del umbral óptimo de decisión ($\tau^* = 0,60$) permitió equilibrar la precisión y la sensibilidad en el conjunto de prueba desacoplado.

Proyección prospectiva: La inferencia para el año 2026 estimó 1918 píxeles ($\approx 172,6 \text{ ha}$) con probabilidad de deforestación superior al umbral establecido. La distribución espacial proyectada se concentra de forma contigua a las áreas previamente transformadas, reproduciendo la dinámica de expansión histórica de la zona.

Limitaciones y trabajo futuro: A pesar de los resultados favorables, el modelo resulta limitado en el alcance espacial analizado, debido al costo computacional de entrenar modelos sobre áreas mas amplias. También esta restricción sobre un núcleo de deforestación activa puede generar un sesgo en el entrenamiento, reduciendo la capacidad de generalización del modelo ante dinámicas de transformación o coberturas vegetales distintas. Como trabajo futuro, se propone escalar la arquitectura hacia extensiones territoriales mayores que resulten mas útiles en la gestión de recursos, como la región Amazónica en su totalidad.

5. Referencias

- [1] Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM), “Boletín de detección temprana de deforestación (dtd) no. 46,” 2026.
- [2] M. C. Hansen, P. V. Potapov, R. Moore, M. Hancher, S. A. Turubanova, A. Tyukavina, D. Thau, S. V. Stehman, S. J. Goetz, T. R. Loveland, *et al.*, “High-resolution global maps of 21st-century forest cover change,” *Science*, vol. 342, no. 6160, pp. 850–853, 2013.
- [3] J. G. C. Ball, K. Petrova, D. A. Coomes, and S. Flaxman, “Using deep convolutional neural networks to forecast spatial patterns of amazonian deforestation,” *Methods in Ecology and Evolution*, vol. 13, no. 11, pp. 2622–2634, 2022.
- [4] Instituto de Hidrología, Meteorología y Estudios Ambientales (IDEAM), “Boletín de detección temprana de deforestación (dtd) no. 45,” 2025.
- [5] Global Land Analysis and Discovery (GLAD), “Global forest change 2000–2025, version 1.13.” <https://storage.googleapis.com/earthenginepartners-hansen/GFC-2025-v1.13/download.html>, 2026. Última versión disponible del conjunto de datos. Accedido: julio de 2026.
- [6] J. G. C. Ball, K. Petrova, D. A. Coomes, and S. Flaxman, “Using deep convolutional neural networks to forecast spatial patterns of Amazonian deforestation: Supplementary materials,” April 2022. Supplement to [3].




Figura 1: Ubicación del área de estudio en el municipio de Mapiripán (Meta). El recuadro destaca la región de 15 x 15 km seleccionada para el análisis de deforestación. Imágenes ©2026 Maxar Technologies, Datos del mapa ©2026 Google.




Figura 2: Superposición espacial de la deforestación proyectada para 2026 sobre el mapa de cobertura forestal histórica en Mapiripán (Meta).




Figura 3: Matriz de confusión del modelo *Baseline* en el conjunto de prueba ($\tau^* = 0,60$).




Figura 4: Cambio de las métricas a través de las épocas modelo *Baseline*.




Figura 6: Clasificación binaria de riesgo de deforestación aplicando el umbral $\tau^* = 0,60$.




Figura 5: Curva ROC obtenida por el modelo *Baseline* en el conjunto de prueba.




Figura 7: Curva Precisión-Exhaustividad (*PR*) para el modelo *Baseline*.